Лекция 4. Нормализация реляционных баз данных

Нормализация — это последовательное преобразование схемы базы данных, при котором каждая таблица описывает ровно одну сущность или одну связь между сущностями. Цель такого преобразования не в том, чтобы сделать схему красивее, а в том, чтобы избавиться от повторов и противоречий. Когда один и тот же факт хранится в нескольких строках, рано или поздно эти копии расходятся, и база начинает давать разные ответы на один вопрос.

Аномалии при работе с данными

Рассмотрим учебный пример: таблицу «Ведомость», в которой рядом с оценкой студента записаны название дисциплины, фамилия преподавателя и номер его кабинета. На первый взгляд это удобно, потому что все сведения собраны в одном месте. Однако при изменении данных такая таблица ведёт себя плохо, и эти неприятности принято называть аномалиями.

Аномалия вставки возникает, когда новый факт нельзя записать без постороннего. Например, нельзя внести в ведомость нового преподавателя, пока за ним не закреплён ни один студент с оценкой. Аномалия обновления проявляется при переезде преподавателя в другой кабинет: номер придётся исправить во всех строках, где упоминается его фамилия, и достаточно пропустить одну строку, чтобы получить противоречие. Аномалия удаления обратна вставке: удалив последнюю оценку по дисциплине, мы вместе с ней теряем и сведения о том, кто эту дисциплину ведёт.

Функциональные зависимости

Строгий язык для разговора о нормализации дают функциональные зависимости. Говорят, что атрибут B функционально зависит от атрибута A, если каждому значению A соответствует ровно одно значение B. Запись A → B читается как «A определяет B». В нашей ведомости номер зачётной книжки определяет фамилию студента, а фамилия преподавателя определяет номер кабинета.

Ключ таблицы — это минимальный набор атрибутов, от которого функционально зависят все остальные атрибуты. Если ключ состоит из

нескольких столбцов, его называют составным. Важно различать полную зависимость, когда атрибут зависит от всего ключа целиком, и частичную, когда для определения значения достаточно только части ключа. Отдельно выделяют транзитивные зависимости, в которых атрибут определяется ключом не напрямую, а через другой неключевой атрибут.

Первая нормальная форма

Таблица находится в первой нормальной форме, если на пересечении каждой строки и каждого столбца хранится одно атомарное значение, а строки не повторяются. Типичное нарушение выглядит как поле «Телефоны», куда через запятую записаны несколько номеров. Искать по такому полю неудобно, а проверить корректность каждого номера средствами самой СУБД практически невозможно.

Чтобы привести таблицу к первой нормальной форме, повторяющиеся значения выносят в отдельную таблицу, где каждая строка хранит один номер и ссылку на владельца. Иногда вместо этого создают несколько столбцов с одинаковым смыслом, например «Телефон1» и «Телефон2», но такой приём лишь маскирует проблему: число столбцов ограничено, а запросы приходится переписывать при каждом изменении.

Вторая нормальная форма

Вторая нормальная форма требует, чтобы таблица уже была в первой нормальной форме и чтобы каждый неключевой атрибут полностью зависел от всего составного ключа. Если ключ ведомости образуют номер зачётной книжки и код дисциплины, то фамилия студента зависит только от первой половины ключа. Это и есть частичная зависимость: фамилия повторяется в каждой строке с оценкой этого студента.

Устраняется частичная зависимость декомпозицией. Атрибуты, зависящие от части ключа, переносят в новую таблицу вместе с этой частью, которая становится её первичным ключом. После разбиения у нас появляются таблицы «Студенты», «Дисциплины» и «Оценки», и в последней остаются только составной ключ и сама оценка.

Третья нормальная форма

Таблица находится в третьей нормальной форме, если она находится во второй и ни один неключевой атрибут не зависит транзитивно от ключа. В таблице «Дисциплины» кабинет определяется преподавателем, а преподаватель определяется дисциплиной. Значит, кабинет зависит от ключа через промежуточный атрибут, и при переезде преподавателя снова придётся править много строк.

Решение аналогично предыдущему шагу: сведения о преподавателях выносятся в собственную таблицу, а в таблице дисциплин остаётся только ссылка на преподавателя. На практике большинство схем стараются довести именно до третьей нормальной формы, поскольку она устраняет основные аномалии и при этом не требует чрезмерного дробления данных.

Нормальная форма Бойса — Кодда

Нормальная форма Бойса — Кодда усиливает третью: в ней левая часть любой нетривиальной функциональной зависимости должна быть потенциальным ключом. Различие между ними заметно только в таблицах с несколькими пересекающимися составными ключами. Классический пример связан с расписанием консультаций, где студент выбирает тему, а каждую тему ведёт один определённый преподаватель.

Приведение к нормальной форме Бойса — Кодда не всегда сохраняет все зависимости, поэтому проектировщику приходится выбирать между строгостью схемы и возможностью проверять ограничения внутри одной таблицы. В учебных задачах этот выбор обычно делают в пользу строгости, а в рабочих системах решение зависит от того, какие запросы выполняются чаще.

Пример декомпозиции

Вернёмся к ведомости и выполним все шаги на конкретных данных. Исходная таблица содержит столбцы: номер зачётной книжки, фамилия студента, группа, код дисциплины, название дисциплины, преподаватель, кабинет и оценка. Ключом служит пара из номера зачётной книжки и кода дисциплины, поскольку один студент получает по одной итоговой оценке за каждую дисциплину.

Фамилия и группа зависят только от номера зачётной книжки, поэтому вместе с ним они уходят в таблицу «Студенты». Название дисциплины и преподаватель зависят только от кода дисциплины и переносятся в таблицу «Дисциплины». Кабинет определяется преподавателем, и на третьем шаге появляется таблица «Преподаватели». В исходной таблице остаются номер зачётной книжки, код дисциплины и оценка.

Обратите внимание, что ни одна строка исходных данных не потерялась: соединив четыре новые таблицы по ключам, мы получим ровно ту же ведомость. Такое свойство называют декомпозицией без потерь, и его стоит проверять после каждого разбиения, особенно когда таблиц становится много.

Четвёртая нормальная форма

Помимо функциональных существуют многозначные зависимости. Они возникают, когда в одной таблице смешаны два независимых списка, например перечень языков, которыми владеет сотрудник, и перечень проектов, в которых он участвует. Чтобы записать все сочетания, приходится повторять каждый язык для каждого проекта, и таблица быстро разрастается.

Четвёртая нормальная форма требует разнести независимые многозначные факты по разным таблицам. После такого разбиения добавление нового проекта больше не требует копировать список языков, а удаление проекта не затрагивает сведения о языках. В повседневной практике эта форма встречается реже предыдущих, но знать о ней полезно.

Денормализация

Нормализация уменьшает избыточность, но увеличивает число соединений, которые приходится выполнять при чтении. В аналитических системах, где данные почти не меняются, а отчёты строятся постоянно, иногда сознательно возвращают часть повторов. Такой приём называют денормализацией, и применять его стоит только после измерений, а не заранее.

Если денормализация всё же нужна, согласованность копий обеспечивают явно: триггерами, материализованными представлениями или регулярным

пересчётом. Главное правило состоит в том, что у каждого факта должен оставаться один основной источник, а все остальные копии считаются производными и могут быть восстановлены.

Порядок проектирования

При проектировании новой схемы удобно двигаться от предметной области. Сначала выписывают сущности и их атрибуты, затем фиксируют функциональные зависимости, о которых известно из требований. После этого для каждой таблицы проверяют условия нормальных форм по очереди и выполняют декомпозицию там, где условия нарушены.

Полезно проверить итоговую схему на тех самых аномалиях, с которых начиналась лекция. Попробуйте добавить преподавателя без студентов, переместить его в новый кабинет и удалить последнюю оценку по дисциплине. Если каждое из этих действий затрагивает одну строку одной таблицы, схема спроектирована удачно.

Вопросы для самопроверки

1. Какие три вида аномалий возникают в ненормализованной таблице и чем они опасны?
2. Чем полная функциональная зависимость отличается от частичной?
3. Почему поле со списком телефонов нарушает первую нормальную форму?
4. Приведите пример транзитивной зависимости из своей учебной практики.
5. В каких случаях денормализация оправдана и как при этом сохранить согласованность?